

Projekt 1 Technologie webowe w procesie analityki danych

Stanisław Olek 275946 Maciej Kędzierski 275963

2026-05-31

Spis treści

1	Analizowane dane	1
2	Model przewidujący oceny	2

1 Analizowane dane

Dane wykorzystane w projekcie zostały pozyskane z oficjalnego API serwisu **Trakt.tv**. Pobieranie danych przebiegało wieloetapowo:

1. Z endpointu `/movies/popular?extended=full&years={rok}` pobrano listę 100 (lub mniej, o ile było to niemożliwe) najpopularniejszych filmów każdego roku na przestrzeni lat 1960–2024
2. Dla każdego filmu wykonano zapytania uzupełniające do endpointów `/movies/{id}/ratings`, `/movies/{id}/people` oraz `/movies/{id}/stats` w celu pozyskania pełnego rozkładu głosów, danych o obsadzie oraz statystyk oglądalności

Ostateczny zbiór danych zawiera 5000 unikalnych rekordów (filmów), opisanych przez 23 cechy:

- **title** (tekstowa): oficjalny tytuł produkcji filmowej
- **year** (ilościowa dyskretna): rok premiery kinowej filmu
- **director** (kategoryczna): imię i nazwisko reżysera (lub reżyserów)
- **actors** (kategoryczna): lista trzech głównych aktorów z obsady filmu
- **language** (kategoryczna): skrót określający oryginalny język filmu (np. “en”, “es”)
- **runtime** (ilościowa ciągła): całkowity czas trwania filmu wyrażony w minutach
- **watchers** (ilościowa dyskretna): całkowita liczba użytkowników platformy, którzy oznaczyli dany film jako obejrzany
- **votes** (ilościowa dyskretna): łączna liczba wszystkich ocen wystawionych filmowi na platformie
- **comment_count** (ilościowa dyskretna): liczba komentarzy i recenzji opublikowanych przez użytkowników serwisu
- **translations_count** (ilościowa dyskretna): liczba dostępnych wersji językowych opisu filmu

- **genres** (kategoryczna): lista gatunków filmowych (np. akcja, dramat) przypisanych do danej produkcji
- **country** (kategoryczna): dwuliterowy kod określający główny kraj produkcji filmu (np. “us”, “pl”)
- **certification** (kategoryczna): oznaczenie kategorii wiekowej określające grupę docelową filmu (np. PG-13, R)
- **rating_1_votes do rating_10_votes** (ilościowa dyskretna): dziesięć oddzielnych cech, z których każda przechowuje dokładną liczbę głosów oddanych na konkretną ocenę z dziesięciostopniowej skali (od 1 do 10)


2 Model przewidujący oceny

Pozyskane dane wykorzystujemy do stworzenia modelu przewidującego oceny. W tym celu wykorzystałem model regresji liniowej, lecz aby z niego skorzystać musimy nasze dane odpowiednio przygotować.

Do ramki danych dodajemy dwie nowe zmienne: *srednia* oraz *wazone_sd*. Jak same nazwy sugerują są to wyliczone średnie i ważone odchylenia standardowe ocen. Zmienna *srednia* posłuży nam do wskazania cech obiektów, które gwarantują największe oceny, a zmienna *wazone_sd* posłuży do wskazania cech obiektów gwarantujących najbardziej spójne oceny. Oprócz tego pozbędziemy się zmiennych, które nie przydadzą się w tworzeniu modelu regresji tj.: *title*, *year*, *director*, *actors*, *genres*, *certification* oraz zmiennych od *rating_1_votes* do *rating_10_votes*.

Zmienne *language* oraz *country* są zmiennymi kategorycznymi, więc aby je sensownie wykorzystać musimy je przesztalcić. W zdecydowanej większości zmienna *language* przyjmuje wartość “en”, mówiąca o tym że oryginalny język filmu to angielski, a zmienna *country* w większości obserwacji przyjmuje wartość “usa”, co oznacza że większość omawianych filmów jest produkowana przez Amerykanów. Przypisujemy wartość 1 dla tych wartości oraz 0 w przeciwnym wypadku. Pozostałe zmienne objaśniające tj.: *runtime*, *watchers*, *comment_count*, *translations_count* przekształcamy dzieląc je przez ich różnicę wartości największej i najmniejszej, aby dostać wartości w podobnej skali; od 0 do nieco ponad 1.


Na tak przygotowane dane nakładamy model regresji, gdzie zmienną objaśnianą jest *srednia*:



Rysunek 1: Wartości współczynników regresji liniowej dla średniej ocen

Na podstawie wykresu [1] możemy stwierdzić, że na średnią ocenę filmu najbardziej wpływa duża liczba użytkowników platformy, którzy oznaczyli dany film jako obejrzany oraz wysoki czas trwania filmu. Mniejszy wpływ na wysoką ocenę filmu ma mała liczba komentarzy i recenzji, mała liczba dostępnych wersji językowych, a także fakt, że oryginalny język filmu jest inny niż angielski. Kraj produkcji wpływu, zdaje się praktycznie nie mieć wpływu na ocenę.

Aby wskazać cechy obiektów gwarantujących najbardziej spójne oceny, nakładamy model regresji, gdzie zmienną objaśnianą będzie *wazone_sd*.




Rysunek 2: Wartości współczynników regresji liniowej dla ważonego odchylenia standardowego ocen

Na podstawie wykresu [2] widzimy, że najmniejsze odchylenie standardowe, a co za tym idzie najbardziej spójne i stabilne oceny otrzymamy, gdy liczba dostępnych wersji językowych filmu oraz liczba użytkowników platformy będą jak największe. Zmniejszenie odchylenia powoduje również

dłuższy czas trwania filmu. Z kolei czynnikami, które wprowadzają największą polaryzację, są duża liczba komentarzy i recenzji oraz to, że oryginalny język filmu to angielski. Kraj pochodzenia zdaje się nie mieć wpływu.

Sprawdźmy jak nasz model radzi sobie w danych, w tym celu przedstawimy wykres rozrzutu, na którym porównamy rzeczywistą średnią ocenę do przewidywanej średniej:




Rysunek 3: Wartości rzeczywiste vs przewidywane średnia

[1] "Średni błąd bezwzględny wynosi: 0.4592"

Na podstawie wykresu [3], widzimy że model nie jest najlepiej dopasowany do danych, głównie przez część obserwacji, których predykcja dość znacząco odbiega od realnego wyniku. Patrząc na średni błąd bezwzględny wnioskujemy, że model przeciętnie myli się o pół oceny, co często może być już dla nas zadowalającą predykcją, pozwalającą ocenić, czy film zbierze pozytywne recenzje, czy też nie.

Zobaczmy jak regresja radzi sobie w prognozowaniu zgodności ocen, metoda działania będzie identyczna jak dla prognozowania średniej:



Rysunek 4: Wartości rzeczywiste vs przewidywane wazone odchylenie standardowe

Na podstawie wykresu [4], widzimy że z prognozowaniem zgodności ocen sytuacja jest podobna, choć w dalszym ciągu duża część odchyłeń jest przewidywana z dużą dokładnością.

Analizując układy punktów na wykresie [3] i wykresie [4], można dostrzec płaski kształt chmury względem linii idealnej predykcji. Nasze modele mają wyraźny problem z przewidywaniem wartości skrajnych (np. ocen powyżej 8.0). Jest to naturalna konsekwencja odrzucenia z modelu regresji silnych zmiennych kategoriycznych (takich jak nazwisko reżysera, obsada aktorska czy gatunek). To właśnie te cechy, nieuchwycone przez podstawowy model, w rzeczywistości najmocniej determinują powstawanie filmowych arcydzieł lub filmów wysoce polaryzujących widownię.